Orkestrasyon MCP v4 cilası — Ralph turu raporu

Tarih: 2026-10-17. Kapsam: tools/orchestrator_mcp. Commit'ler push edilmedi.

Ne değişti

Story	Değişiklik	Kanıt
US-001/002	Çevrimdışı + canlı benchmark harness (evals/bench.py), GitHub/arXiv araştırması (ARASTIRMA.md/.pdf)	test_bench.py 3 test
US-003	Aider tarzı SEARCH/REPLACE edit formatı; büyük dosyada tam metin yerine yalnız değişen blok	test_edits.py 10 test; sentetik büyük dosyada yanıt ≥%95 küçük
US-004	Model output token limit reached artık yeniden denenir, bütçe ikiye katlanır (üst sınır 16384); düzyazıya sarılı/kesik çitli JSON çıkarılır; kapsam dışı dosyada açıklayıcı geri bildirim; `ORCHESTRATOR_RETRY_CONTEXT=full\	clean` test_ada
US-005	Hesap başına kimlik/proje cache'i (TTL 600 sn, 401/403'te düşer, hatalı listeleme cache'lenmez). 3 üretimde auth-files çağrısı 3 → 1	test_speed.py 5 test
US-007	apply aşamasında yeni eklenen API anahtarı / özel anahtar / bearer token reddedilir; hata mesajı sırrı içermez	test_secrets.py 6 test; reviewer düzeltmeleri: kapsam hatası dosya adını verir, mevcut dosyadaki sır yeni sırrı gizleyemez, 401 ile yarışan listeleme önbelleğe yazılmaz

Test durumu: 84 test geçti (test_secrets, test_speed, test_adaptive, test_edits, test_bench, test_orchestrator, test_robustness), omc ralph verify rc=0.

Canlı önce/sonra (6 görev × 2 tekrar, gemini-3.8-flash-high, 15 hesaplık havuz)

Metrik	Önce (fdaf7c12)	Sonra, retry=full	Sonra, retry=clean
Geçme oranı	1,00	1,00	1,00
İlk denemede geçme	1,00	1,00	1,00
Süre (ort. sn / koşu)	5,59	6,12	5,12
Toplam token / koşu	1410	1776	1798
Çıktı token / koşu	384	402	425

Ham veri: live-bench-before.json, live-bench-full.json, live-bench-clean.json.

Kötüleşen metrik (açıkça)

• **Token +%26.** Neden: SYSTEM istemine edit formatı talimatı eklendi (~60 token/çağrı). Bu görev setinde dosyalar küçük (<60 satır), edit formatı hiç tetiklenmedi; kazancı yalnız büyük dosyada görülür (sentetik testte ≥%95 yanıt küçülmesi). Canlı ölçümde kazancı **kanıtlanmadı**.

• Süre farkı (5,1–6,1 sn) 2 tekrarda gürültü sınırında; iyileşme ya da kötüleşme iddia edilmez.

Ölçülemeyen / açık

• **Retry bağlamı A/B (full vs clean) sonuçsuz.** Dört canlı koşuda hiç yeniden deneme olmadı (ilk denemede geçme 1,00); iki kolu ayıracak veri çıkmadı. Varsayılan full kaldı (davranış değişmedi). Ayırıcı bir ölçüm için ilk denemede başarısız olması muhtemel görevler gerekir.

• Edit formatının canlı token kazancı: büyük dosyalı görev seti gerekir.

• 18 araçlı sunucunun gerçek bir MCP istemcisinde (Antigravity) yeniden bağlanması test edilmedi.

• feedbackCommands yeni test dosyalarını içermiyor; bunlar elle koşuldu.

Kota harcaması

Canlı: 3 benchmark koşu kümesi × 2 tekrar × 6 görev = 36 üretim çağrısı. Bench total_tokens_mean koşu başına (6 görev) değerdir; toplam ≈ 2 × (1410 + 1776 + 1798) ≈ **10k token**. Gemini yalnız bu MCP'nin testleri için kullanıldı.