Kaynak sadakati araştırma testi: Sonnet tek vs Gemini MCP + sonda orkestratör kontrolü

Tarih: 2026-10-17. Karar (Enes): site/oyun/uygulama işi orkestratörün kendisinde kalır, Gemini'ye gitmez; kaynak sadakati kritik araştırma Gemini MCP ile denenir ve en son orkestratör kontrol eder. Bu rapor yalnız ikinci kısmı ölçer.

Düzenek

Konu: serbest iş parçacıklı (free-threaded) Python. Altı kaynak yerel metin olarak donduruldu (PEP 703, PEP 779, PEP 684, free-threading HOWTO, 3.13 ve 3.14 What's New). İki kol aynı görevi aldı: 12 iddia, her biri en çok 30 kelimelik birebir alıntı ve kaynak kimliği; ilk 8 iddia sabit konulara bağlı.

• Kol A: Sonnet 5.5 tek başına okur ve yazar.

• Kol B: Sonnet 5.5 orkestratör; altı Gemini işçisi (kaynak başına bir) iddia ve alıntı çıkarır; orkestratör alıntıları quote_check.py ile kaynakta mekanik doğrular, geçmeyeni atar, raporu kurar.

Puanlama: (1) alıntı kaynakta birebir var mı, mekanik ve bağımsız betikle; (2) kör Opus hakem, rastgele X/Y etiketi, iddia alıntı tarafından destekleniyor mu ve 8 konu kapsandı mı.

Sonuç

Ölçü	Sonnet tek (A)	Gemini MCP + kontrol (B)
Alıntı kaynakta birebir (mekanik)	12/12	12/12
Hakem: destekli / kısmi / desteksiz	11 / 1 / 0	11 / 1 / 0
Zorunlu 8 konudan kapsanan	8/8	7/8 (PEP 703'ün ne önerdiği yok)
Sonnet token (ham)	102.510	99.888
Sonnet token (74.498 taban çıkarılmış)	28.012	25.390
Süre	46,7 sn	67,8 sn
Gemini token (ek)	0	115.736

Gemini işçilerinin ürettiği 60 alıntının 2'si kontrolü geçemedi (biri 30 kelimeyi aştı, biri kaynakta yok); orkestratör ikisini de kullanmadı. Kontrol olmasaydı B raporunda uydurma alıntı olabilirdi.

Yorum

• Sadakat: iki kol eşit. B'nin güvencesi sondaki mekanik kontrol; işçi ham çıktısı tek başına güvenilmez (60 alıntıda 2 hata, %3,3).

• Maliyet: Claude tokenı neredeyse aynı (ham -%2,6). Altı kaynak küçük olduğu için A grep ile hızlı okudu; orkestrasyon kazancı büyük kaynak setinde beklenir, burada ölçülmedi.

• Hız: B 1,45 kat yavaş.

• Kalite ayrıntısı: B'nin raporunda bir iddia alıntısından fazlasını söylüyor, bir iddia (PEP 779 bellek yüzdesi) yazıldığı tarihteki durumu güncel gibi sunuyor; A'da bir iddia alıntıdan azını destekliyor.

Karar önerisi: kaynak sadakati kritik işte Gemini işçi kullanılabilir, ama yalnız mekanik alıntı kontrolü ve orkestratör gözden geçirmesiyle; bu testte token veya hız avantajı göstermedi, yalnız yük dağıtımı. Kaynak seti büyüdükçe fark değişebilir.

Sınırlar

• Tek koşu (n=1), tek konu, altı kaynak.

• Kendi seçtiğim konu ve konu listesi; hakem tek Opus ve X konumu yanlılığı olabilir.

• Mekanik kontrol alıntının varlığını doğrular, anlamını değil; anlam için hakem var.

• B kolu MCP stdio yerine aynı kütüphaneyi orch_cli.py ile kullandı.

• Gemini token son deneme sayımıdır.

Dosyalar

res/task.md, res/quote_check.py, res/score_res.py, res/sources/*, run/A_res/report.*, run/B_res/report.*, judge_res/verdict.json, judge_res_map.json.